生活服务类智能聊天机器人

远程科研实习项目

课程(项目)名称: 生活服务类智能聊天机器人

专业: 计算机科学与技术

学生姓名: 刘曹扬

2019年8月17日

1

目录

摘要

- 一、背景
 - 1.1 聊天机器人
 - 1.2 生活服务类程序的发展
- 二、课堂知识回顾与梳理
 - 2.1 第一节课
 - 2.2 第二节课
 - 2.3 第三节课
 - 2.4 第四节课
- 三、任务分析及思路
- 四、项目设计与实现效果
 - 4.1 项目模块化设计
 - 4.1.1 意识识别和实体抽取
 - 4.1.2 查询类消息的处理
 - 4.1.3 饮食服务推荐请求的处理
 - 4.2 项目实现效果
- 五、心得体会

摘要

伴随着人工智能浪潮的袭来,我们生活的各行各业都逐渐体会到了 其带来的便利,但伴随着智能生活的普及,人们对其的要求也逐渐提高, 需求也逐渐的变得多样性起来。本项目以此次课程所授予的知识内容出发,结合自身探索与所学,通过设计一个智能的聊天机器人,完成自己在人工智能领域启蒙的第一步。

该项目主要是为了生活服务所设计,在现当下我们的生活与外卖APP、打车 APP等一系列生活类 APP紧密相连,尤其对于许多繁忙的工作人士,这些已然成为了他们生活中不可或缺的一部分。但是在生活中我们往往会遇到一些突发的情况影响我们使用这些 APP.而本项目就是为了更好地对这些生活便利类的服务进行整合,使得其更好地服务大众。

而关于此次项目,本项目采用 python 进行编程,借助 rasa_nlu、Spacy等工具,利用正则表达式进行问话查询,同时也利用了状态机实现了多轮多次查询。通过美团外卖的 API 接口,实现了生活服务信息的查询。

本次项目进行实现时并不顺利,最初的设想因为软件 API 的缺少而不得不中途放弃,不得不对项目的方向进行修改,对于该项目,后续的优化一方面通过百度 APi 的语音识别技术添加语言助手,使其更加便利,另一方面则是希望添加更多的生活类 APP 的 API 接口以满足更多的生活中的需求例如打车或者导航之类。

关键词: SPACY、API、人工智能、状态机

一、背景

1.1 聊天机器人

聊天机器人是一个在线聊天系统,最早诞生于 20 世纪 80 年代,是通过理解聊天对象的句子自动做出相应应答的一种软件,它可以代替真人进行聊天,但准确地理解自然语言。

世界上最早的聊天机器人诞生于 20 世纪 80 年代,这款机器人名为"阿尔贝特",用 BASIC 语言编写而成。但今天的互联网上,已出现诸如"比利"、"艾丽斯"等聊天机器人。据悉,还有一个"约翰•列侬人工智能计划",以再现当年"甲壳虫"乐队主唱的风采为目标。

聊天机器人(chatterbot)是一个用来模拟人类对话或聊天的程序。"Eliza"和 "Parry"是早期非常著名的聊天机器人。它试图建立这样的程序:至少暂时性地让一个真正的人类认为他们正在和另一个人聊天。

Chatterbots 已应用于在线互动游戏 Tinymuds。一个单独的玩家可以在等待其他"真实"的玩家时与一个 chatterbot 进行互动。目前至少有一个公司正在制造一种产品,这种产品让你建立一个 chatterbot 以便用来掌握相关市场或关于你网站的其它问题。不难想象两个 chatterbots 互相交谈甚至互相交换关于自身的信息,如此一来,他们的对话将会变得更为复杂。(看看人工智能就会知道这个想法如果实现了会引起怎样的惊慌)。当然,他们可以使用更多普通的聊天缩略词。四

中文聊天机器人技术的发展 基于中文聊天的机器人技术也日趋成熟,国内已经出现了不少智能聊天机器人,比如赢思软件的小i,爱博的小A,小强,和爱情玩偶等等。这些机器人也已经日益成为网民上网的好伙伴。赢思软件推出的小i还有很多丰富的功能,比如 MSN 群,让办公室白领能够更加轻松的交流。

另外,聊天机器人也被应用到了商务和政务领域,很多网站上已经有了 msn 机器人或者 web 机器人, 让互动交流变得更加方便和人性化。

1.2 生活服务类程序的发展

近几年国内的 APP 开发市场正在发生着巨大的变化,从社交 APP、商城 APP、教育 APP 的开发,渐渐的转向了城市本地生活服务 APP 的开发。

随着手机智能化的发展不仅仅带动了手机 APP 开发市场,也带动了生活的智能化进程。在这智慧生活里面,肯定少不了本地生活服务 APP 的功劳,相信只有两者相辅相成才能够实现真正的智慧生活,才能真正的服务于人们生活。

除了智慧生活,还有大家比较熟悉的 o2o 模式的本地生活服务类,本地生活服务最早出现于 2003年,那时是以本地生活服务网站的形式出现。随着智能手机的发展,在 2013年,全面 讲入手机应用 APP 软件时代。

在近几年的发展,生活服务移动软件的类型也是越来越多,市场的份额也是越来越大。而 我国有 13 亿的人口,这个人口红利对于开发生活服务 APP 软件来说是极为的有利,从美团、大 众点评 APP 软件,到滴滴打车等生活服务应用软件,这些生活服务 APP 手机应用软件的出现, 无疑不是在为生活服务市场的壮大提供有利的条件。

移动互联网市场的跟新迭代,各种类型的应用软件交替出现,唯有本地生活服务 APP 的留存时间是最久的,虽然生活服务应用软件不是最常用的 APP 软件,但就是它的实用便捷性让现代的人越来越离不开它。这也就是为什么现在越来越多的互联网大头都来抢占这以市场的原因。

生活服务 APP 软件能有很好的发展趋势吗?答案是肯定的,生活服务 APP 一定能有很好的市场发展前景,因为手机是大家离不开的,生活与每个人息息相关,本地生活服务手机 APP 开发,必定会有无限大的市场前景。特别是现在家居、生活智能化进程快速发展,生活服务移动 APP 的发展前景必定广阔。

二、课堂知识回顾与梳理

2.1 第一节课

老师首先从需要掌握在 IntelliJ 等 IDE 中创建,使用虚拟环境说起,介绍了一些编程工具例如 Spyder、Pycharm、IntelliJ。而本次课正式从 Watson NLP 开始进入本次聊天机器人的具体课程。概念上来说本次项目需要完成一个自动的开放式领域问答,通过给予大量自然语言问题与大范围知识,希望机器给出精准答案、精准的自信度、答案的理由以及快速的响应时间。老师通过举出 Deep Blue 的例子帮助更好地了解这一想法,并且通过介绍阿尔法元介绍了深度学习——当前机器学习领域中蓬勃发展的技术。接下来老师通过从人语言的特点(模糊、上下文相关、隐晦)出发,介绍了知识图谱的形成:大量的文本=》解析(句法结构)=》概化,形成语义框架。由此介绍了相关技术的应用领域,如健康医疗、疾病诊断、教育支持等。同时老师介绍了他自己产生想法的初始原因与本次项目的核心内容:使用正则表达式和机器语言从自由格式文本中提取含义从而构建聊天机器人。

2.2 第二节课

第二节课的第一个重点讲的是理解意图与理解实体,首先介绍了正则表达式,介绍了其中的字符与字符组

符号	描述
*	字符出现零次或者多次 如: a*
	或 如: A a
^/\$	开始/结束 如: ^A a\$
[]	匹配 [ABC]
{m}	a{2} 至少出现2次
${m,n}$	出现的次数高于m,小于n次
[::]	特殊的匹配 如: [:digit:] 任何数字 [:alpha:] 任何字
	符 [:space:] 空字符
1	可以有4种不同的含义: 1.自己2引用下一个字符3
	引入操作者 4.什么都不做
+	字符出现1次或者多次 a+
?	出现0次或者1次
•	代表除了空字符的任意字符
()	分组表达,作为一个子表达式
[==]	指定等价
\n	向后引用 \
[]	指定一个排序元素,如多字符元素

接着老师介绍了正则表达式的使用:用正则表达式识别实体

■ 用正则表达式识别实体

```
In [1]: pattern = re.compile('[A-Z]{1}[a-z]*')
In [2]: message = """

Mary is a friend of mine,
she studied at Oxford and
now works at Google"""
In [3]: pattern.findall(message)
Out[3]: [(Mary', 'Oxford', 'Google']
```

而后便开始介绍词向量:

- 1. 词向量试图用一个固定长度的数值向量表示单词的含义
- 2. 出现在类似的上下文中的单词具有相似的向量
- 3. 词向量是计算密集型的, 训练它需要大量数据
- 4. 高质量的词向量可供任何人使用
- 5. GloVe 算法(word2vec 派系)
- 6. Spacy
- 7. 向量的方向很重要,单词之间的"距离"=向量之间的角度
- 8. *相反与无关不同

■ 词语语义的相似度

向量的方向很重要

单词之间的"距离"=向量之间的角度

余弦相似度

1:向量指向相同的方向(词语语义高度相关)

0:它们是垂直的(词语语义并无相关)

-1:它们指向相反的方向(词语语义完全相反)

最后老师介绍了实体抽取的三种方法:

- 1. 预建的命名实体识别
- 2. 角色(利用正则表达式)
- 3. 依赖分析

2.3 第三节课

第三节课老师介绍了一种更加智能的聊天机器人:虚拟助手,其需要外部的信息,同时也需要与数据库或 API 进行交互,由此老师便介绍了一些基础的 SQL 语句。接着老师便介绍了 rasa-nlu。(Rasa_nlu:NLU 的职责是接受一个句子或是陈述,输出一个能够被机器人使用的"意图","实体"和"置信度"。Rasa 基本上提供了一个在各种 NLP 和 ML 库之上的高层次的 API 来负责"意图"的分类和"实体"的提取)由此老师便介绍了如何用程序实现多轮单次查询以及否定实体。

2.4 第四节课

第四节课首先介绍了如何实现一个有状态的机器人,这其中便涉及到了询问队列,询问队列是一个可重复使用的模式,它的过程如下,待处理的操作返回两个值 action和 pending_action,将 pending_action保存在外部作用域,如果得到"是"意图且有待处理的操作,我们便执行它;如果得到"否"意图,我们便擦除任何待处理的操作接着老师介绍了人工智能当前的前沿技术:神经对话模型(LSTM),它的特点是由一个序列到另一个序列,可应用于文本摘要(摘要的扩充/文章的删减)

最后老师介绍了API的调用,以 iexfinance 为例详细介绍了使用方法与相应效果, 并对其他软件的 API 接口也进行了扩充。

三、任务分析与思路

本项目的目的是构建一个生活服务类的聊天机器人。 经对课上知识点梳理,可将项目分为以下的步骤:

- 1.对于输入的信息进行意图识别,判断意图
- 2. 根据意图,来对意图中的实体进行识别
- 3. 根据二者利用接口进行查询和访问获得所需的信息
- 4. 根据信息的性质进行预处理后,转换形式进行响应

初期我的目标是做一个票务相关的机器人,但是相关软件都没有开放他们的 API 接口或是网站页面具有反爬虫的机制,故更改了方向以其他的生活服务入手,进行编程。但在初期的编程过程中,通过测试,总是发现机器人对用户的意图识别有所误差,对聊天类与查询类的信息不能很好的进行区分,故先采用聊天类的询问方式,待意图明确后进行查询类的聊天

四、项目设计与实现效果

4.1 项目模块化设计

4.1.1 意识识别与实体抽取

对于意图识别,通过使用自己处理的语料,并通过 rasa 和 spacy 进行处理,产生相应的预测模型,然后通过对其的加载,成功对其的功能进行操作。

4.1.2 查讯类消息的处理

进入到该部分的途径是在意图识别和实体抽取环节中用户的信息被识别为查询类消息,且实体明确。由于对于不同特点的消息,要采取不同的策略去处理,多变的聊天类消息应 当用较为自由的方式去处理,但是一旦进入到了功能查询部分,由于该部分的信息存在有连贯性和逻辑性的要求,则需要此部分的操作应当较为流程化。故本项目采用了状态机来处理实现了带遗留任务,状态等待转换,拒绝甄别与处理的多轮多次查询。

4.1.3 饮食服务推荐请求的处理

有时,用户的需求可能并不是查询一些特定生活服务的相关信息,例如饭店。他们可能仅仅是对当地一无所知,希望得到系统的推荐,来作为自己的投资参考,在这种情况下,通过请求接口的方式去获得相关服务显得较为合适.

4.2 项目实现效果

五、心得体会

这一次的远程项目是我第一次真正意义上接触到了自然语言处理这个领域,在这长达一个月的学习期间,我的 python 编程能力有了很大的提升,同时也通过老师的介绍,充分的认识到了人工智能的前景与自己未来可做的方向。

这次的远程科研,代码完成与项目实现是一个方面,但更重要的是让我学会了一些计算机学习与科研过程中所需要具有的良好习惯,以前我总喜欢光看一些文章,但始终没有对如何自己产生问题、思考问题、解决问题没有头绪,但在这一次的课堂上张老师就很清晰的展示了如何产生自己研究方向的方法。与此同时,此次的远程科研给我提供了更多的计算机学习方向上的可能,课堂上老师虽然时间有限,有一些技术不能很展开的进行讲解,但在后续的自己复习中便发现这些知识所构成的知识谱系,如诺努力掌握,必在今后的生涯中受益匪浅,就比如这次课上的 rasa 与spacy,于项目中我们只是对其进行了引用,但其的文档还有所能涉及到的相关知识他们的能量亦是巨大的。在以前我只草草接触过机器学习,对其的了解只停留于一些概念,在编程与想法上是不足的,而这一次的远程科研使我在实战中有所提升,让我对于今后的编程有了更多的想法。

除此之外,这次的收获还有就是让我坚定了信心,以前我总是容易被编程中的困难打倒,由此消极怠工,就比如张老师此次提到的有很多的工程师因为被在软件中配置虚拟环境所难倒从而放弃了这个职业,我也曾犯过诸如此类的错误,但在这一次的项目中当第一节课老师提到这个的时候,我认识到在未来的生涯中总会遇见一些问题,有的时候只是咬一咬牙的努力,便也许可以翻过眼前的大山,希望自己可以在未来工作的路上能一直坚持下去,记住这次项目中得到的觉悟。